



왼쪽 — 선호 점수 회복률

후보 두 개의 확률만 읽은 값. 1 = 오염이 없던 상태까지 회복

오른쪽 — 실제 준수율

조항을 건 채 이름을 생성시켜 쓴 값. 표기 맞춤 × 과제 맞춤



값 조향을 넣은 층 — Qwen2.5 L25 · DeepSeek L20 · Llama-3.2 L15 · StableCode L18 · 조건은 모델마다 준수율이 가장 높은 것

■ 무개입

■ 값 조향 (우리)

■ Spotlight (기존)